

Projekt č. 1 - Vigenèrova šifra KRY

Bc. Marián Kapišinský (xkapis00)

4.4.2021

Obsah

1	Index koincidencie	2
2	Friedmanov test	3
3	Kasiského test	5
4	Určenie dĺžky kľúča	6
5	Určenie kľúča	7
	Literatúra	8

1 Index koincidence

V implementácií sa využíva výpočet indexu koincidence $I_c(x)$ (1.1), ktorý je definovaný ako pravdepodobnosť, že dva náhodné prvky x sú identické, kde $x = x_1, x_2, \dots, x_n$ je reťazec znakov dĺžky n , a f_i je frekvencia i -teho znaku daná celým číslom ako počet výskytov i -teho znaku v skúmanom zašifrovanom texte (uvažujeme 26 znakovú anglickú abecedu) [1].

$$I_c(x) = \frac{\sum_{i=0}^{25} f_i(f_i - 1)}{n(n - 1)} \quad (1.1)$$

2 Friedmanov test

Friedmanov test vychádza z indexu koincidencie (1.1). Uvažujeme 26 znakovú anglickú abecedu, pre ktorú určíme hodnotu indexu koincidencie reťazca v anglickom jazyku (2.1), a hodnotu indexu koincidencie zcela náhodného reťazca, t.j. všetky znaky majú rovnakú frekvenciu (2.2) [1]. Dĺžku kľúča r potom určíme podľa vzorca 2.3, kde n je dĺžka a $I_c(x)$ je index koincidencie zašifrovaného textu [2].

$$I_c \approx \sum_{i=0}^{25} p_i^2 = 0.065 \quad (2.1)$$

$$I_c \approx 26 \left(\frac{1}{26} \right)^2 = 0.0385 \quad (2.2)$$

$$r \approx \frac{(0.065 - 0.0385)n}{(n-1)I_c(x) - 0.0385n + 0.065} \quad (2.3)$$

Pozn.: Hodnota p_i značí frekvenciu výskytu i -teho znaku anglickej abecedy podľa tabulky 2.1.

Znak	Frekvencia	Znak	Frekvencia
a	0.08167	n	0.06749
b	0.01492	o	0.07507
c	0.02782	p	0.01929
d	0.04253	q	0.00095
e	0.12702	r	0.05987
f	0.02228	s	0.06327
g	0.02015	t	0.09056
h	0.06094	u	0.02758
i	0.06966	v	0.00978
j	0.00153	w	0.02360
k	0.00772	x	0.00150
l	0.04025	y	0.01974
m	0.02406	z	0.00074

Tabuľka 2.1: Frekvencie znakov anglického jazyka [2]

3 Kasiského test

Pre Kasiského test [2] som zvolil dĺžku n-gramov 3 až 8 vrátane. Pre každý n-gram v zašifrovanom texte vyhládám všetky pozície, na ktorých sa vyskytuje. N-gramy, ktoré sa vyskytnú len raz a n-gramy, ktoré sa už preskúmali, sa preskočia. Následne sa z pozíc vypočítajú vzdialenosti medzi všetkými n-grammi ako rozdiel aktuálnej a predchádzajúcej pozície. Zo vzdialeností sa potom nájde ich najväčší spoločný deliteľ. Náhodné výskyty n-gramu sú ošetrené tak, že ak nejaká vzdialenosť spôsobí, že najväčší spoločný deliteľ je rovný 1, tak sa táto hodnota zahodí. Výsledné hodnoty (potenciálne dĺžky kľúča) menšie ako 3 sa zahodia taktiež. Následne sa zo všetkých hodnôt vyberie najčastejšia hodnota a tá sa považuje za správnu dĺžku kľúča.

4 Určenie dĺžky kľúča

Pre určenie dĺžky hesla opäť využívam index koincidencie. Vieme, že pre anglický jazyk je jeho hodnota približne 0.065. Táto hodnota je približne rovnaká pre zašifrovaný text vytvorený monoalfabetickou šifrou. Takže, ak od prvého znaku textu zoberieme každý r -tý znak (tj. znaky na indexoch $1, 1+r, 1+2r, \dots$), kde r je dĺžka kľúča, hodnota indexu koincidencie tohto podreťazca by mala byť podobná hodnote v anglickom jazyku [1]. Za predpokladu, že minimálna dĺžka kľúča je 4, pre každú hodnotu, počínajúc minimálnou dĺžkou až po hodnotu 200 vrátane¹, vytvorím podreťazec $c = c_1 c_{1+r} c_{1+2r} c_{1+3r} \dots$, a ak bol tento podreťazec vytvorený správnou hodnotou r , tak hodnota indexu koincidencie bude približne 0.065. V implementácii teda hľadám prvé r , pre ktoré bude hodnota indexu koincidencie väčšia, rovná 0.060. Prvé r beriem z dôvodu, že všetky násobky tejto hodnoty mali podobného hodnoty, a ak som vyberal maximum zo všetkých hodnôt, veľmi často bola vybraná nespráva hodnota r .

¹vlastné zvolené obmedzenie dĺžky kľúča

5 Určenie kľúča

V tomto kroku predpokladáme už známu dĺžku hesla r . Z pôvodného zašifrovaného textu vytvoríme podreťazce podľa vzorca 5.1. Následne na každý z týchto podreťazcov aplikujem vzorec 5.2 pre každé g , kde g je posuv abecedy, p_i je frekvencia i -tého znaku podľa tabulky frekvencií 2.1, f_i je frekvencia i -tého znaku v podreťazci a n je dĺžka podreťazca [1]. Pre každý podreťazec dostanem pole hodnôt M_g a za výsledný znak kľúča vyberiem to g , pre ktoré je hodnota najvyššia, t.j. ak má najvyššiu hodnotu napr. M_3 , znamená to, že znak kľúča bude c .

$$\begin{aligned}c_1 &= c_1 c_{1+r} c_{1+2r} c_{1+3r} \dots \\c_2 &= c_2 c_{2+r} c_{2+2r} c_{2+3r} \dots \\&\cdot \\&\cdot \\&\cdot \\c_r &= c_r c_{r+r} c_{r+2r} c_{r+3r} \dots\end{aligned}\tag{5.1}$$

$$M_g = \sum_{i=0}^{25} \frac{p_i f_{i+g}}{n}\tag{5.2}$$

Literatúra

- [1] HANÁČEK, P. *Kryptografie, Část 1, Klasická kryptografie: Souhrnné materiály*. 2021.
- [2] LEWAND, R. E. *Cryptological Mathematics*. 1. vyd. The Mathematical Association of America, 2000. ISBN 0-88385-719-7.